Witmem
知存科技

WITMEM 语音芯片工具链
用户使用说明

版本号：V1.3.0
日期：2024.7.29

声明

商标声明：

作为北京知存科技有限公司的商标，本文件中提到的所有其他商标和商号均为其持有人的财产。

版权声明：

内容声明：

本文件中的信息如有更改，恕不另行通知。为了确保内容的准确性，文章会做出相关的确认，但本文件中的所有声明、信息和建议不构成任何明示或暗示的保证。

目录

1 环境配置

1.1 简介

本文主要介绍语音芯片工具链 witin_mapper 的使用。该工具链主要针对各种神经网络设计，用于将神经网络运算 map 到 WTM1001/WTM2101 芯片上，生成相应的配置文件和烧录文件。其中烧录文件需使用专门的工具烧写到 WTM1001 和 WTM2101 的 ARRAY 阵列中，配置文件集成到 sdk 中使用。

1.2 前端支持

前端转换支持 tensorflow，onnx，pytorch 深度学习框架。

1.3 版本信息

Ubuntu:18.04.5
Cmake 3.16（18.04 默认是 3.10 版本，需升级）

1.4 安装方式

1.4.1 Docker 方式

方式一：
预先在 windows 系统或者 Liunx 系统下安装 docker 环境。
1.获取镜像：gzip -d witin_tc_wtm2101_vX.X.X.tar.gz（docker 目录下）
2.加载镜像：docker load -i witin_tc_wtm2101_vX.X.X.tar
3.查看镜像：docker images
4.创建容器：
docker run -it --name xxx witin_tc witin_toolchain_wtm2101:vX.X.X /bin/bash
5.查看容器：docker ps -a
6 重新进入容器：1)docker start container_id ; 2)docker attach container_id
7 退出容器：exit
8 将本地文件（或文件夹）上传至容器：
docker cp 本地文件路径 container_id:/workspace/witin_mapper

9 将容器文件（或文件夹）下载至本地：

docker cp container_id:/workspace/witin_mapper 本地文件路径

10.使用 witin mapper 生成的网络的映射配置，一般存放于 witin_mapper/output 路径下，可以使用 docker cp 将其从 docker 容器内拷贝到本地，以供后续步骤的烧录工具和精度分析工具使用。

方式二：

1.拉取镜像：

docker pull witin/witin_toolchain_wtm2101:vX.X.X

2.查看镜像：

docker images

3.创建容器：

docker run -it --name xxx witin/witin_toolchain_wtm2101:vX.X.X /bin/bash

4.查看容器：

docker ps -a

5.启动容器

docker start container_id

docker attach container_id

6.进入容器,默认进入 workspace 路径

7.如若不用，退出容器，执行 exit 即可。

说明：2024 年 6 月份后，中国大陆境内使用方式 2 获取 docker 镜像会失败。

2 工程说明

build：存放安装脚本，output 输出文件目录以及 WTM1001/WTM2101 模拟器

model：存放示例的模型文件

python： 存放整个工程的 python 文件

tests：部分测试文件

run.py：利用 python3 命令执行部分 tests 文件中的测试文件

README.md：对整个 witin_mapper 工程进行说明

3 使用流程

3.1 模型导入

以 tensorflow 为例，调用接口函数如下：

1．首先调用 tensorflow 接口函数来读取 pb 文件得到 graph_def

with gfile.FastGFile(model_path, ‘rb’) as f:

graph_def=tf.GraphDef()

graph_def.ParseFromString(f.read())

sess.graph.as_default()

tf.import_graph_def(graph_def, name=’’)

2．调用前端转换函数

witin_frontend.frontend.from_tensorflow(graph_def, shape_dict)

其中 graph_def 为读取 pb 文件得到的文件，shape_dict 为输入节点的名字和形状，字典形式。调用该函数后得到 mod 和 params 两个参数，其中 mod 为图的结构中间表示，params 为用到的参数。

3.2 编译 build

该步骤通过编译得到 WTM1001/WTM2101 上运行的配置文件，然后将该配置文件集成到 sdk 然后下载到芯片中并运行，即可完成整个网络的在 WTM1001/WTM2101 芯片上的运行。

首先配置 target 为 npu，target_host 为 npu，然后调用如下接口函数：

```
    with witin.transform.PassContext(opt_level=3):
            _, _, _, npu_graph =
witin_frontend.build_module.build(
                mod,
                target='npu',
                target_host='npu',
                params=params,
                input_data=input_dt,
                chip="BB04P1",
                optimize_method_config=optimize_method_config,
                output_dir=output_dir,
                array_distribute=array_distribute)
```

其中：

mod 为 2.1 中模型导入后得到的 mod 表示

target 和 target_host 为 npu

params 为模型导入后得到的 params 文件

input_data 参数为 witin 阵列 Array 校准需要用到的输入数据，推荐至少为 100 组输入。

chip 为使用的芯片版本。

optimize_method_config 为优化配置文件，默认为空字符串""。

output_dir 为输出文件的保存路径，默认为"./build/output"。

array_distribute 为指定权重布局分配的文件，默认为空字符串""，当指定此文件时，会最小化 build 模型，只保留一些必要文件。

在调用 build 后，在工程的 build 的 output 文件夹下会生成如下几个文件和文件夹：

1. net_config.h/net_config.c 文件，配置文件，需集成到 witin 的 sdk 中使用
2. map 文件夹，存放烧写 array 需要用到的 expected_in.bin，expected_out.bin，layers.txt 以及 map.csv 文件。
3. simulator_input 文件夹：存放模拟器仿真输入文件
4. simulator_output 文件夹：存放运行仿真后的输出文件
5. params 文件夹：存放各层映射的权重文件，用于 debug
6. layer_debug 文件夹：存放各层仿真器的输出输出文件，用于 debug 及精度调试工具。

3.3 运行 run

该部分主要提供 build 之后在 witin 的模拟器进行运行的接口。

build 完成后会在 build 的 output 文件下生成配置文件和烧写文件。同时会返回 npu_graph 到 python 端。该 npu_graph 可用于创建 runtime 的 module，然后打注输入并运行，最后得到网络运行的结果。具体函数接口如下：

- m=npu_graph_runtime.create(npu_graph, "BB04P")，创建运行时 module m。
- m.set_input('in1', wintin.nd.array(data)),其中 data 为 np.array 的列表，'in1'为 input placeholder 的名字。
- m.run()，在模拟器上运行。
- m.get_output(0)，得到在模拟器上运行的结果。

3.4 与 tensorflow 结果进行比对

设置阈值 threshold，调用 compare_tensorflow_with_npu 函数比较 tensorflow 的运行结果 tf_out_data 和 witin npu 的运行结果。

3.5 与 pytorch 结果进行比对

(1)构建网络模型

```
    class Net(nn.Module):
        def __init__(self):
            super(Net, self).__init__()
            self.conv1 = nn.Conv2d(1, 10, kernel_size=3, stride=1)
            self.conv2 = nn.Conv2d(10, 14, kernel_size=5, stride=3)
            self.fc = nn.Linear(896, 10)
        def forward(self, x):
            in_size = x.size(0)
            x = F.relu(self.conv1(x))
            x = F.relu(self.conv2(x))
            x = x.view(in_size, -1)  # flatten the tensor
            x = self.fc(x)
            return x
```

(2)传入模型和输入，得到 script_model。

```
    input_shape = [1, 1, 28, 28]
    shape_list = [(input_name, input_shape)]
    model.load_state_dict(model_dict)
    data = torch.rand(input_shape)
    scripted_model = torch.jit.trace(model, data).eval()
```

(3)调用前端转换函数，得到 mod 和 params

```
    mod, params = witin_frontend.frontend.from_pytorch(scripted_model,
shape_list)
```

调用该函数后得到 mod 和 params 两个参数，其中 mod 为图的结构中间表示，params 为用到的参数。

(4)编译 build

```
    with witin.transform.PassContext(opt_level=3):
            _, _, _, npu_graph = witin_frontend.build_module.build(
                                                mod,
                                                target=target,
                                                target_host=target_host
,
                                                params=params,
                                                input_data=input_dt,
                                                chip=chip)
```

(5)运行 run，和模拟器出来的结果进行对比

```
    m = npu_graph_runtime.create(npu_graph, chip)
    m.set_input(input_name, witin.nd.array(data))
    m.run()
    witin_output_list = [m.get_output(i).asnumpy() for i in range(1)]
```

3.6 多网络

支持多网络，详细请参照工程：
witin_mapper/tests/onnx/witin/wtm2101/operator/test_forward_multinet.py
多网络 set_input()的时候，要指定网络输入节点的名称或网络的序号,例如：

```
# 1.已知输入节点的名称
m.set_input('fingerprint_input', witin.nd.array(data1))
m.set_input(fingerprint_input', witin.nd.array(data2))
# 2.不知道节点名称，按照 Graph 的顺序
m.set_input(0, witin.nd.array(data1))
m.set_input(1, witin.nd.array(data2))
```

单网络可任意设置节点名称。

3.7 优化策略

为了优化 array 的计算精度，可以设置不同层的优化策略。
现在有支持三种优化策略：输入数据优化、权重数据优化、权重数据复制。
详细定义信息如下：

```
syntax="proto3";

enum SpMatMode{
SIM_MODE = 0;
MIX_MODE = 1;
DIG_MODE = 2;
}

enum ArrayRegion {
ANY_REGION = 0;
UP_REGION = 1;
DOWN_REGION = 2;
}

message LayerOptiConfig{
string name = 1;

message InputOpti{
int32 shift = 1; // 0 left 1 right
```

```
int32 num = 2;
int32 front_scale = 3;
int32 signed_input = 4;
}

message WeightOpti{
int32 shift = 1;
int32 num = 2;
ArrayRegion region = 3;
}

message DoubleWeightOpti{
int32 multiple = 1;
}

message SparseMatrixOpti{
SpMatMode sp_mode = 1;
int32 shift = 2;
}

message ArrayOutputOpti{
int32 magnify = 1;
int32 repeat = 2;
}

message ConvOpti{
int32 multi_point = 1;
bool tdnn_mode = 2;
bool conv2DToConv1D_enable = 3;
int32 fout_burst_point = 4;
}

repeated InputOpti inputOpti = 2;
repeated WeightOpti weightOpti = 3;
repeated DoubleWeightOpti doubleWeightOpti = 4;
repeated SparseMatrixOpti sparseMatrixOpti = 5;
repeated ArrayOutputOpti arrayOutputOpti = 6;
repeated ConvOpti convOpti = 7;
```

```
}

message OptimizeConfig{
repeated LayerOptiConfig layerOptiConfig = 1;
}
```

其中，name 为要优化的层名，为字符串；InputOpti 为输入数据优化；WeightOpti 为权重数据优化；DoubleWeightOpti 为权重数据复制；SparseMatrixOpti 为稀疏矩阵模式，ArrayOutputOpti 为输出放大优化模式，ConvOpti 为卷积优化模型。

详细参考工程：

witin_mapper/tests/python/frontend/onnx/witin/wtm21011/optimizer/test_layer_optimize_method.py

在 build 中指定 optimize_method_config 参数，为优化策略配置文件。

3.7.1 输入数据优化

```
message InputOpti{
int32 shift = 1;
int32 num = 2;
int32 front_scale = 3;
int32 signed_input = 4;
}
```

- 当需要此层输入数据数据扩大时：
  1. 设置 shift 为 1 时且 num>1，会扩大本层输入的输入，扩大的倍数为 2^num。注意：当此层为首层时，需要人工将数据扩大输入，非首层时，要求前一层必须有 Relu。
  2. 设置 front_scale>0 时，会将本层的上层 scale 值缩小，缩小倍数为 2^front_scale。注意：此优化不可用于首层。
- 当首层输入为有符号数 int8 时：

设置 signed_input = N > 0。注意：对于有符号输入 X，需要在程序输入的时候手动将输入改变：

1. X1 = X[0:N]
2. X2 = X[N:end] + 128
3. X3 = -X[0:N]
4. 将 X1,X2,X3 拼接一起
5. X' = np.concatenate((data0, data1, data2), axis = 1)
6. 将负数变为 0

7．X'[X'<0] = 0

8．得到新的输入 X'(uint8)

参考示例程序为：

witin_mapper/tests/python/frontend/onnx/witin/wtm21011/optimizer/test_layer_optimize_method_signed_in.py

注意：v001.000.024 及以前版本，当首层输入数据为有符号数 int8 时，需要按照上述过程处理，v001.000.025 及以后版本支持首层输入数据为有符号数 int8 类型。

3.7.2 权重数据优化

message WeightOpti{
int32 shift = 1;
int32 num = 2;
ArrayRegion region = 3;
}

当需要此层权重数据扩大时：

设置 shift 为 1 时且 num>1，会扩大本层输入的输入，扩大的倍数为 2^num。

例如，权重为 2*3 的矩阵[[1,2,3][4,5,6]]，设置

```
weightOpti {
        shift : 1
        num : 1
   }
```

权重变为[[2,4,6][8,10,12]]。

region 为权重分配区域指定：

ANY_REGION = 0; // 任意区域
UP_REGION = 1; // 上半区
DOWN_REGION = 2; // 下半区

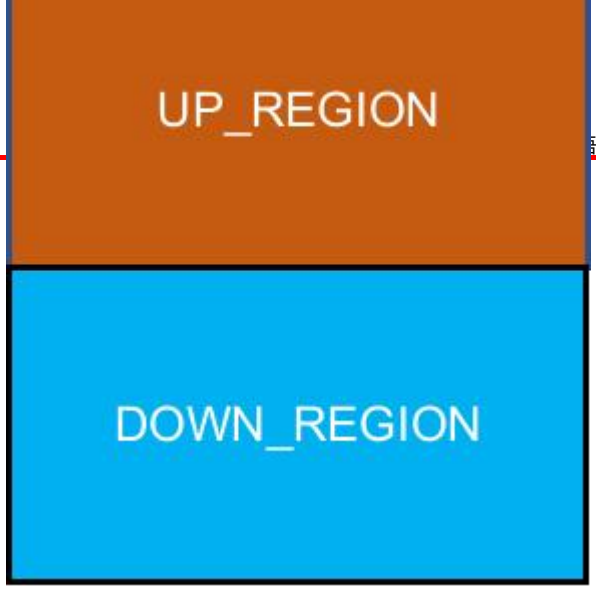

3.7.3 权重数据复制

message DoubleWeightOpti{
int32 multiple = 1;
}
当需要对权重复制时使用：
设置 multiple >1，会复制本层的权重，复制的倍数为 2^ multiple。
例如，权重为 2*3 的矩阵[[1,2,3][4,5,6]]，设置
doubleWeightOpti {
multiple : 1
}
权重变为 4*3 的矩阵[[1,2,3][4,5,6],[1,2,3][4,5,6]]。

3.7.4 稀疏矩阵优化

message SparseMatrixOpti{
SpMatMode sp_mode = 1;
}
enum SpMatMode{
SIM_MODE = 0;
MIX_MODE = 1;
DIG_MODE = 2;
}
稀疏矩阵适用于权重大小超过 array 存放限制，即[-275,275]之间时配置，可以将权重分为高 8 位和低 8 位，其中低 8 位使用 array（NPU）进行计算，高 8 位使用 CPU 计算，最后相加可得最终结果。

由于大部分高位部分是 0，所以是一个稀疏矩阵，但是当高位部分非 0 值较多时，可能会导致空间不足无法布置，mapper 会给出错误。

此优化选项分为三种模式：

SIM_MODE 为默认模式，纯 NPU 计算，权重范围为[-275,275]。

MIX_MODE 为混合模式，低位使用 NPU，高位使用 CP，高低位皆为 8bit。

DIG_MODE 为数字模式，纯 CPU 计算，此模式只适用于 kernel shape 很小时的计算，以解决 NPU 模拟计算精度不足的问题，权重范围为[-128,127]。

3.7.5 输出放大优化

```
message ArrayOutputOpti{
int32 magnify = 1;
int32 repeat = 2;
}
```

magnify 直接将当前层 scale 值缩小，方法为右移 magnify 位数。

repeat 复制倍数，2^repeat 次： 插入同样的 op_conv 算子再插入一个 add_op 和 scale_op，将 op 与 op_conv 输出结果通过 add_op 相加然后通过 scale_op 除 2，在 round 中可以使用后处理 add 结果移位实现除 2，如下图所示。

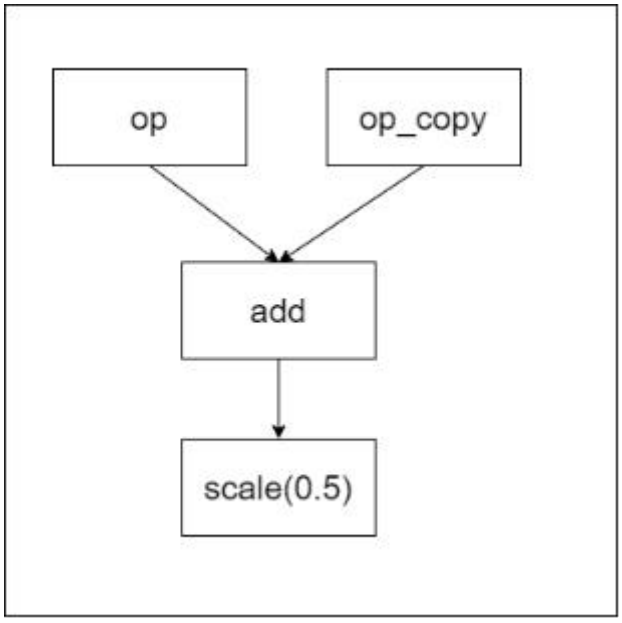

3.7.6 卷积优化

```
message ConvOpti{
int32 multi_point = 1;
bool tdnn_mode = 2;
bool conv2DToConv1D_enable = 3;
}
```

此处是设定卷积的计算模式和多点并行数(加速计算)。

multi_point 为多点并行个数，设置 multi_point，需要将 tdnn_mode 或者 conv2DToConv1D_enable 为 ture 的情况下，而 tdnn_mode 和 conv2DToConv1D_enable 不能同时为 ture。

tdnn_mode:DCCRN 单独计算模式

conv2DToConv1D_enable：将 2D 卷积在 W 方向进行拆分，根据 2D 卷积计算原理，需要在 W 方向进行划窗，将 W 方向划窗的动作单独拆分为一层。

在 WTM2101 中，卷积有两种计算：普通卷积模式和 tdnn 卷积模式。

普通卷积模式是指卷积按照通常计算方法，即连续完成多次滑窗得到最终的输出 feature map，如果加速多点计算，需将 conv2DToConv1D_enable 设置为 ture，此时 tdnn_mode 必须为 false。

而 tdnn 卷积模式是将 W 方向上赋予时间序列信息，并按照 tdnn 模式计算，多用于 DCCRN 网络中，同时需将 tdnn_mode 设置为 ture，此时 conv2DToConv1D_enable 必须为 false。

3.8 特殊配置环境变量

3.8.1 Array 分配

因为硬件制作原因，有些芯片的前 N 列的 Array 计算会有较大误差，在烧写芯片测试后若发现可能为此方面的原因，可以设置环境变量：

export ARRAY_ALLOC_RESERVED_COLUMN=N

跳过前 N 列的 Array 分配。

在进行 Array 分配时，默认的搜索超时时间比较短，通常在 10s~100s 之间，具体跟权重块的数量相关，在网络权重块比较多的场景下，可能搜索不到最优解或无解，可以通过环境变量设置超时时长，设置如下：

export `ARRAY_ALLOC_TIMEOUT_LIMITS = 300`

3.8.2 开启 FIFO

硬件支持 fifo 的使用，可以在 TDNN 的情况下提高数据输入的效率，不开启时需要一次输入 TDNN 的所需的所有帧数据，开启后可以只输入一帧数据，通过设置环境变量：

export WITIN_FIFO_EN = 1

开启。

注意：开启此选项可能导致 regfile 空间不足，若出现此问题，可尝试关闭。

3.8.3 设置校准数据数量

校准文件 expect_in/out 用于板卡烧写测试模型的准确率，文件默认有 100 帧的校准数据，若需要增大、减小数据的个数，可以设置环境变量：

export WITIN_EXPECTED_NUM=N

会保存 N 帧的校准数据。

4 Onnx 模型

4.1 创建 Tensor

1．创建 tensor 数据，为 int8 数据(-128~127)，shape 为[514,128]，最终的数据类型为 float32。

```
    params = np.random.randint(-128, 127, size = (514, 128), dtype
= np.int32).astype(np.float32)
```

2．创建 onnx tensor，参数分别为：tensor 名称，数据类型，大小，值。

```
    params_tensor = onnx.helper.make_tensor("params_tensor",
                                            data_type=onnx.TensorPro
to.FLOAT,
                                            dims=(514, 128),
                                            vals=params.flatten())
```

4.2 onnx 算子

Onnx 模型支持自定义算子。

常用算子有 Gemm（矩阵乘、全连接层、DNN 层），Tdnn（时延神经网络），Add（向量加），Relu（激活函数-relu），Scale（标量乘），LSTM（长短期记忆网络），GRU（门控循环单元），

ActLut（自定义激活函数查找表），Mul(向量乘)。

常见算子列表					
序号	算子名称	作用	序号	算子名称	作用
1	Gemm	矩阵乘、全连接层、DNN 层	8	GRU	门控循环单元
2	Tdnn	时延神经网络	9	ActLut	自定义激活函数查找表
3	Add	向量加	10	Mul	向量乘

4	Relu	激活函数-relu	11	LSTM	长短期记忆网络
5	Scale	标量乘	12	Average Pool	平均池化
6	Concat	对指定维度进行拼接	13	Conv	卷积
7	Slice	切片操作	14	ConvTranspose	转置卷积

注: Tdnn、GRU、LSTM 和 ActLut 算子为自定义算子, 因此它们必须用 onnx 模型，同时也建议其他算子也使用 onnx 构建网络模型。

4.2.1 Gemm

一般矩阵乘法（General Matrix multiplication）。

```
    node = onnx.helper.make_node('Gemm',
                                 inputs=['input', 'params',
'bias'],
                                 outputs=['output'],
                                 name='dnn_node0')
```

其中，

inputs list[tensor]为输入、权重、偏置

outputs list[tensor]输出

name string节点名称

注意：Gemm 后通常跟一个“scale”节点，代表 G 值。

4.2.2 Tdnn

时间延迟网络（Time Delay Neural Network）。

```
    node = onnx.helper.make_node('Tdnn',
                                 inputs=['input', 'params'],
                                 outputs=['output'],
                                 time_offsets=offsets,
                                 bias_params=bias,
                                 scale_params=1024,
```

```
                                        name='tdnn_node0')
```

其中，

inputs list[tensor]输入、权重

outputs list[tensor]输出

time_offsets tensor时延信息

biastensor偏置

scale_paramsfloat缩放值（G 值）

name string节点名称

4.2.3 Lstm

长短期记忆网络。

```
   lstm6_node = onnx.helper.make_node(
           'Lstm',
           inputs=['conv5_reshape_out', 'lstm6_w_ifo_tensor',
'lstm6_w_c_tensor', 'lstm6_b_ifo_tensor', 'lstm6_b_c_tensor'],
           scale_ioft=1024*2,
           scale_ct=1024,
           activate_type=['sigmoid', 'tanh', 'tanh'],
           activate_table=act_table,
           shift_bits=[0,0,-7, -7],
           clean_ctht=10,
           outputs=['lstm6_out'],
           name="lstm6")
```

其中，

inputs list[tensor] 输入、ioft 权重、ctl 权重、ioft 偏置、ct 偏置

scale_ioft float ioft 部分 G 值

scale_ct float ct 部分 G 值

activate_typelist[string]激活表的类型，只能为 sigmoid/tanh

activate_table tensor激活表，每个激活表长度为 256，LSTM 有三个为[3,256]

shift_bits list[int] 长度为 4，

[0]为对 ft*ct(16bit)结果的移位数值，

[1]为对 it*ctl(16bit)结果的移位数值，

[2]为对 ft*ct(16bit)+it*ctl(16bit)的结果 ct(16bit)移位数值，

[3]为对 ot(8bit)*tanh2_ct(8bit)的结果 ht(16bit)移位数值，

不设置默认为[0,0,-7,-7]。

clean_ctht int 表示 htct 在执行该设置次数后置为 0，当 clean_ctht 设置为

0 或者不设置，为不清除 ht/ct.

outputs list[tensor] 输出 Tensor

name string 节点名称

计算公式如下：

$$iof_t = sigmoid(W_{iof} * (x_t, h_{t-1}))$$
$$c_{tl} = tanh_1(W_{ct} * (x_t, h_{t-1}))$$
$$c_t = f_t * c_{t-1} + i_t * c_{tl}$$
$$h_t = tanh_2(c_t) * o_t$$

4.2.4 Gru

门控循环单元。

```
    node = onnx.helper.make_node(
            'Gru',
            inputs=['in', 'gru_zrt_params', 'gru_ht_params',
'gru_zrt_bias', 'gru_ht_bias'],
            scale_zr=1024,
            scale_ht=1024,
            activate_type=['sigmoid', 'tanh'],
            activate_table=act_table,
            shift_bits=[-7, -7],
            outputs=['out'],
            name="gru_node1")
```

其中，

inputs list[tensor]输入、zrt 权重、ht 权重、zrt 偏置、ht 偏置

scale_zr float zrt 部分 G 值

scale_ht float ht 部分 G 值

activate_typelist[string]激活表的类型，只能为 sigmoid/tanh

activate_table tensor激活表，每个激活表长度为 256，Gru 有两个为[2,256]

shift_bitslist[int]长度为 2，

[0]为对 rt(8bit)*ht(8bit)的结果 ct(16bit)移位，

[1]为对[(1-zt)*ht](16bit)+[zt*ht~](16bit)的结果 ht(16bit)移位，

不设置默认为[-7,-7]。

outputs list[tensor]输出 Tensor

name string节点名称

计算公式如下：

$$z_t = \sigma\left(W_z \cdot [h_{t-1}, x_t]\right)$$
$$r_t = \sigma\left(W_r \cdot [h_{t-1}, x_t]\right)$$
$$\tilde{h}_t = \tanh\left(W \cdot [r_t * h_{t-1}, x_t]\right)$$
$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$$

4.2.5 Scale

标量乘。

```
node = onnx.helper.make_node('Scale',
                             inputs=['in'],
                             outputs=['out'],
                             scale=0.0009765625)
```

其中，

inputs list[tensor]输入

outputs list[tensor]输出

scale float缩放值

注意：scale 的值取值范围为[-128,127] U (-1,1)。当 scale 的值为(-1,1)时，scale 的值只支持 2^-n，n 为整数，n<=13：n<8 时，为后处理乘法，使用移位进行计算。n>=8，n<=13 时，若 scale 层跟在 Gemm 层、Conv2d 层后，代表为上层 Gemm/Conv2d 的 G 值，即最小 G 值为 256，最大为 8192；若不跟在 Gemm 层、Conv2d 层后，则为单独的乘法计算。当 scale 的值取值范围为[-128,127]时，scale 只能为其中的整数。

4.2.6 Relu

激活函数。

```
node = onnx.helper.make_node('Relu',
                             inputs = ['input'],
                             outputs = ['output'])
```

其中，

inputs list[tensor]输入

outputs list[tensor]输出

4.2.7 ActLut

自定义激活查找表函数，通过 int8 的数据范围-128~127 的映射表，映射为激活输出。

```
node = onnx.helper.make_node('ActLut',
                             inputs=['in'],
                             outputs=['out'],
                             act_type='sigmoid',
                             table_params=act_table)
```

其中，

inputs list[tensor]输入

outputs list[tensor]输出

act_typestring激活表类型，可选为 sigmoid、tanh

table_paramstensor激活表 tensor，为[1,256]大小

注意：查找表的对应方式为：源输入[0~127] 对应查找表下标 0~127，源输入[-128~-1]对应查找表下标 128~255，即：输入[-128~127]的二进制转变为无符号形式为[128~255,0~127]，对应为查找表下标。

4.2.8 Mul

乘

```
node = onnx.helper.make_node('Mul',
    inputs=['in', 'mul_x'],
    outputs=['out'],
)
```

其中，

inputs list[tensor]输入，左乘数，右乘数

outputs list[tensor]输出

注意：如果左乘数和右乘数都为向量时，它们的 shape 要求相等；也支持左乘数和右乘数其中一个是向量，另外一个是标量的情况。

4.2.9 Add

加

```
node = onnx.helper.make_node('Add',
                             inputs = ['in', 'add_x'],
                             shift_bit = -1,
                             outputs = ['out'])
```

其中，

inputs list[tensor] 输入，左加数，右加数

shift_bit int 表示对 add 后的结果移位，负数表示右移，正数表示左移，默认 0

outputs list[tensor] 输出

注意：如果左加数和右加数都为向量时，它们的 shape 要求相等；也支持

左加数和右加数其中一个是向量，另外一个是标量的情况。

4.2.10 Averagepool

平均池化。

```
    left_ave_pooling_node = onnx.helper.make_node(
            "AveragePool",
            inputs=["conv16_left_add_relu"],
            outputs=["out"],
            kernel_shape=[35, 2],
            pads=[0, 0, 0, 0],  #[top,left,bottom,right]
            strides=[1, 1],
            scale_in=0.0625,
            scale_out=0.0625)
```

其中，

inputs list[tensor] 输入、权重、偏置

outputs list[tensor] 输出

kernel_shape list 池化核 shape

pads list 填充

strides list 步长

scale_in float 输入缩放尺度，默认为 1

scale_out float 输出缩放尺度，默认为 1

4.2.11 Slice

切片操作。

```
    conv3_1_left_slice_node = onnx.helper.make_node(
                "Slice",
                inputs=["gemm3_left_reshape_out",
"conv3_1_left_slice_starts", "conv3_1_left_slice_ends",
"conv3_1_left_slice_axes", "conv3_1_left_slice_steps"],
                outputs=["conv3_1_left_slice_out"])
```

其中，

inputs list[tensor] 输入、切片起始索引、切片结束索引、切片指定轴、切片步长

outputs list[tensor] 输出

4.2.12 Concat

数据拼接。

```
concat_node = onnx.helper.make_node(
        "Concat",
        inputs=["concat_in1","concat_in2"],
        outputs=["deconv7_concat"],
        axis = 1)
```

其中，

inputs list[tensor] 输入：左拼接数，右拼接数

outputs list[tensor] 输出

axis int 指定拼接轴，目前 WTM2101 仅支持 axis=1.

4.2.13 Conv

卷积。

```
conv3_node = onnx.helper.make_node("Conv",
                inputs=['conv2_relu', 'conv3_w_tensor',
'conv3_b_tensor'],
                outputs=['conv3'],
                kernel_shape=[3, 2],
                strides=[2, 1],
                pads=[1, 1, 0, 0],
                name="conv3")
```

其中，

inputs list[tensor] 输入、权重、偏置

outputs list[tensor 输出

kernel_shape list[int] 卷积核 shape

strides list[int] 滑动步长

pads list[int] 填充

name string 节点名称

注意：

1）在构建 onnx 模型权重维度是[O,I,H,W],经工具链内部转换，维度转换为[O,W,H,I],最终 shape 为[O,W*H*I]；

2）在工具链内部，卷积 feature map 维度为[N,W,H,C].

4.2.14 ConvTranspose

转置卷积。

```
deconv12_node = onnx.helper.make_node("ConvTranspose",
```

```
            inputs=['deconv_input', 'deconv_weight', 'deconv_bias'],
            outputs=['deconv_output'],
            kernel_shape=[3, 2],
            strides=[2, 1],
            pads=[1, 0, 1, 0],
            output_padding=[1, 0, 1, 0],
            name="deconv_node")
```

其中，

inputs list[tensor] 输入、权重、偏置

outputs list[tensor 输出

kernel_shape list[int] 卷积核 shape

strides list[int] 滑动步长

pads list[int] 填充

output_padding list[int] 输出填充

name string 节点名称

注意：

注意：

1) 在构建 onnx 模型权重维度是[I,O,H,W],经工具链内部将权重转换为等价的 Conv，转换后维度转换为[O',W',H',I'],最终 shape 为[O’,W’*H’*I’];

2）在工具链内部，转置卷积的 feature map 维度为[N,W,H,C];

3）在 WTM2101 工具链中，转置卷积主要应用在 DCCRN 场景中.

4.2.15 Gru2Array

```
   新增双权重 GRU 部署方式，其接口如下：
   gru_node1 = onnx.helper.make_node('Gru2Array',
            inputs=['in', 'gru_params1', 'gru_params2', 'gru_bias1',
'gru_bias2'],
            input_offset=0,
            hidden_shift_bit=-1,   #输入 scle
            scale_input=1024,
            scale_hidden=1024,
            scale_ones = 128,
            activate_type=['sigmoid', 'tanh'],
            activate_table=act_table,
            shift_bits=[-7, -7, -2, -3],
            clean_ht=0,
            outputs=['out'],
            name="gru_node1")
```

```
    inputs list[tensor]输入、input_zrn 权重、hidden_zrn 权重、input_zrn 偏置、
hidden_zrn 偏置
    input_offset：对输入的偏移量，暂未适配，现仅保留接口
    hidden_shift_bit：对 array 计算后的 hidden_zrn 进行移位，“-”代表右移位
    scale_input float 表示 input_zrn 部分 G 值：
    scale_hidden float 表示 hidden_zrn 部分 G 值
    activate_typelist[string]激活表的类型，只能为 sigmoid/tanh
    activate_table tensor 激活表，每个激活表长度为 256，或者 1024，目前建议取
长度为 1024
    shift_bitslist[int]长度为 2，
    [0]为对 rt(8bit)*hn(8bit)的结果(16bit)移位，
    [1]为对[(1-zt)*ht](16bit)+[zt*ht~](16bit)的结果 ht(16bit)移位，
    [2]为对(1-zt)*ht 移位，如果不移位，必须设置为 0
    [3]为对 zt*ht~进行移位，如果不移位，必须设置为 0
    不设置默认为[-7,-7,-7,-7],-7 表示右移七位，-代表右移位。
    outputs: list[tensor],输出 Tensor
    name string:节点名称
    scale_ones：表示“1”和 zt 的缩放尺度，目前支持-128~128
    clear_ht:gru 执行如果次数后，将 ht 清零，等于 0 时，代表不清除 ht
```

4.3 创建 graph

节点列表

```
    nodes = [node0, node1]
```

图的名称

```
    name = 'model_name'
```

输入信息

```
    inputs=[onnx.helper.make_tensor_value_info("in",onnx.Tensor
Proto.FLOAT,list(in_shape))]
```

输出信息

```
    outputs=[onnx.helper.make_tensor_value_info("out",
onnx.TensorProto.FLOAT,list(out_shape))]
```

初始化 Tensor

```
    initializer=[tensor1, tensor2, tensor3]
```

```
    graph = onnx.helper.make_graph(nodes,
                                   name,
                                      inputs,
                                      outputs,
                    initializer
     )
```

4.4 保存 graph

```
model=helper.make_model(graph, producer_name=model_name)
with open(ROOT_DIR + model_name + '.onnx', "wb") as of:
        of.write(model.SerializeToString())
```

4.5 导入模型

```
onnx_model = onnx.load(file_path)
```

5 常见问题和说明

5.1 Array 分配 error

```
[10:53:27] [ERROR]low_level_mapping/src/tensor/array_alloc_cp.cpp:169: Failed to allocation array memory

[10:56:07] [ERROR]low_level_mapping/src/tensor/array_alloc_cp.cpp:174: Allocation Result After extend column:
Layer Name ~ Layer Type ~ Weight Size ~ Bias Size ~ Weight Region ~ Bias Region
gemm_node0 ~ OpType::MV_OP ~ [235x123] ~ [ 1x123] ~ [896-1131][256-379] ~ [10-11][256-379]
gemm_node1 ~ OpType::MV_OP ~ [235x123] ~ [ 1x123] ~ [235-470][640-763] ~ [15-16][640-763]
gemm_node2 ~ OpType::MV_OP ~ [235x123] ~ [ 1x123] ~ [  0-235][768-891] ~ [ 9-10][768-891]
gemm_node3 ~ OpType::MV_OP ~ [235x123] ~ [ 1x123] ~ [470-705][640-763] ~ [14-15][640-763]
gemm_node4 ~ OpType::MV_OP ~ [235x123] ~ [ 4x123] ~ [896-1131][379-502] ~ [ 7-11][379-502]
gemm_node5 ~ OpType::MV_OP ~ [235x123] ~ [ 1x123] ~ [470-705][1024-1147] ~ [15-16][1024-1147]
gemm_node6 ~ OpType::MV_OP ~ [235x123] ~ [ 4x123] ~ [  0-235][640-763] ~ [ 7-11][640-763]
gemm_node7 ~ OpType::MV_OP ~ [235x123] ~ [ 4x123] ~ [  0-235][512-635] ~ [ 4- 8][512-635]
gemm_node8 ~ OpType::MV_OP ~ [235x123] ~ [ 4x123] ~ [235-470][896-1019] ~ [ 1- 5][896-1019]
gemm_node9 ~ OpType::MV_OP ~ [235x123] ~ [ 4x123] ~ [896-1131][768-891] ~ [ 5- 9][768-891]
gemm_node10 ~ OpType::MV_OP ~ [235x123] ~ [ 4x123] ~ [1131-1366][256-379] ~ [11-15][256-379]
gemm_node11 ~ OpType::MV_OP ~ [235x123] ~ [ 1x123] ~ [1131-1366][128-251] ~ [ 9-10][128-251]
gemm_node12 ~ OpType::MV_OP ~ [235x123] ~ [ 1x123] ~ [470-705][1152-1275] ~ [ 8- 9][1152-1275]
gemm_node13 ~ OpType::MV_OP ~ [235x123] ~ [ 4x123] ~ [  0-235][384-507] ~ [ 1- 5][384-507]
gemm_node14 ~ OpType::MV_OP ~ [235x123] ~ [ 4x123] ~ [  0-235][256-379] ~ [ 6-10][256-379]
gemm_node15 ~ OpType::MV_OP ~ [235x123] ~ [ 4x123] ~ [  0-235][896-1019] ~ [ 5- 9][896-1019]
gemm_node16 ~ OpType::MV_OP ~ [235x123] ~ [ 4x123] ~ [1366-1601][512-635] ~ [11-15][512-635]
gemm_node17 ~ OpType::MV_OP ~ [235x123] ~ [ 4x123] ~ [1366-1601][896-1019] ~ [ 9-13][896-1019]
gemm_node18 ~ OpType::MV_OP ~ [235x123] ~ [ 4x123] ~ [235-470][768-891] ~ [ 1- 5][768-891]
gemm_node19 ~ OpType::MV_OP ~ [235x123] ~ [ 4x123] ~ [1131-1366][1024-1147] ~ [11-15][1024-1147]
gemm_node20 ~ OpType::MV_OP ~ [235x123] ~ [ 1x123] ~ [896-1131][640-763] ~ [ 6- 7][640-763]
gemm_node21 ~ OpType::MV_OP ~ [235x123] ~ [ 1x123] ~ [896-1131][1152-1275] ~ [15-16][1152-1275]
gemm_node22 ~ OpType::MV_OP ~ [235x123] ~ [ 1x123] ~ [470-705][512-635] ~ [10-11][512-635]
gemm_node23 ~ OpType::MV_OP ~ [235x123] ~ [ 4x123] ~ [1366-1601][128-251] ~ [ 5- 9][128-251]
gemm_node24 ~ OpType::MV_OP ~ [235x123] ~ [ 4x123] ~ [470-705][128-251] ~ [11-15][128-251]
gemm_node25 ~ OpType::MV_OP ~ [235x123] ~ [ 4x123] ~ [  0-235][128-251] ~ [ 1- 5][128-251]
```

提示：

[ERROR]low_level_mapping/src/tensor/array_alloc_cp.cpp:169: Failed to allocation array memory

说明 array 分配超出限制，需重新调整网络结构或者优化方式。

5.2 Regfile 空间不足

```
[11:10:54] [ERROR]low_level_mapping/src/memory/mem.cpp:284: No enough memory to alloc, Need: 771
Max memory len: 8192
Mode: FIFO_DISABLED
Free Blocks Size: 1
Free Blocks List:
begin:7616      length :576     state : FREE
Used Blocks Size: 15
Used Blocks List:
begin:0 length :160     state : USED
begin:160       length :800     state : USED
begin:960       length :160     state : USED
begin:1120      length :800     state : USED
begin:1920      length :800     state : USED
begin:2720      length :160     state : USED
begin:2880      length :800     state : USED
begin:3680      length :160     state : USED
begin:3840      length :800     state : USED
begin:4640      length :800     state : USED
begin:5440      length :160     state : USED
begin:5600      length :800     state : USED
begin:6400      length :160     state : USED
begin:6560      length :800     state : USED
begin:7360      length :256     state : USED
```

提示：

[ERROR]low_level_mapping/src/memory/mem.cpp:284: No enough memory to alloc, Need: 771

说明 regfile 资源不够使用，需重新调整网络结构。

5.3 SRAM 空间不足

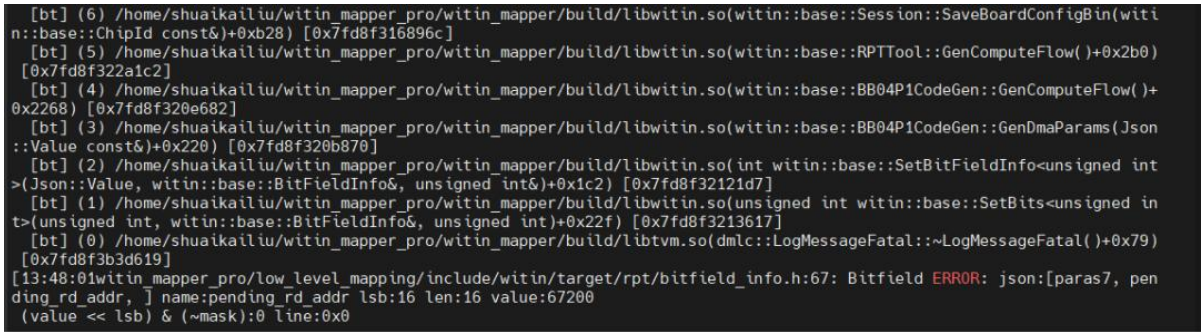

提示：

Bitfield ERROR: json:[paras7, pen ding_rd_addr,] name:pending_rd_addr lsb:16 len:16 value:67200

说明：SRAM 资源不足，需重新调整网络结构。

5.4 输入类型错误

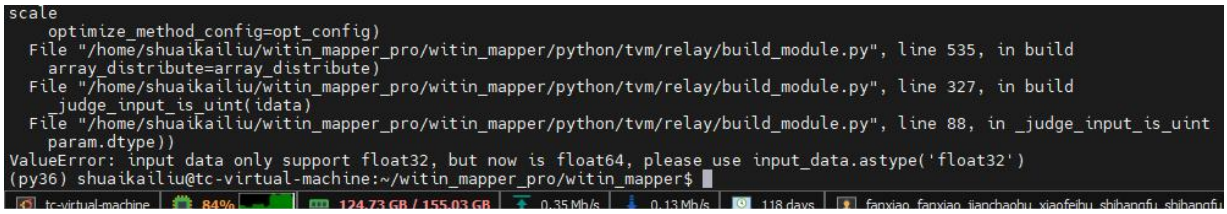

提示：

ValueError: input data only support float32, but now is float64, please use input_data.astype('float32')

说明：输入数据类型有无，应使用 input_data.astype('float32')。